



COMPAS: LA IA QUE DECIDE QUIÉN VA A LA CÁRCEL

Análisis de sesgo racial y
robustez adversaria bajo el
Reglamento Europeo de IA

Santiago Álvarez Geanta · Taron Sargsyan
· Joaquín Sigüenza Chilar

Comenzar





Imagina que un algoritmo decide tu libertad...

2x

Se equivoca el doble de veces si eres negro.
Un sistema que debería ser objetivo reproduce el racismo sistémico.

Esto no es ciencia ficción. Pasa en tribunales reales de EE.UU.
Un algoritmo juzga tu futuro antes que un juez. Y tiene prejuicios que no puede admitir.

Siguiente →

¿Qué es COMPAS?

Software de Northpointe que asigna a cada acusado una "nota de riesgo" de reincidencia. Los jueces lo utilizan para decidir sobre prisión preventiva y sentencias. Un algoritmo que juzga tu futuro antes que cualquier juez humano.



Caso State v. Loomis: condenado con ayuda de una caja negra. Ni el acusado ni su abogado podían inspeccionar el algoritmo que decidió su destino.



El Escándalo de 2016

ProPublica destapó la verdad incómoda: la tasa de falsos positivos para acusados afroamericanos DUPLICABA la de los caucásicos. Gente inocente marcada como peligrosa por su raza. El algoritmo "objetivo" reproducía el racismo sistémico.

2x

Más errores:

Impacto:

Afroamericanos inocentes etiquetados como "alto riesgo" el doble de veces que caucásicos.





COMPAS

¿Quién crees que reincidió?

El algoritmo se equivocó... sistemáticamente. Dos casos reales demuestran cómo COMPAS falla de manera predecible y sesgada.

CASO A

Chaval negro, 18 años, faltas menores → "ALTO RIESGO"
Resultado: NO reincidió

CASO B

Hombre blanco, 41 años, delitos graves previos → "BAJO RIESGO"
Resultado: SÍ reincidió

Nuestro Trabajo

Replicamos y ampliamos el análisis sobre el dataset COMPAS-two-years (~6.000 casos reales de tribunales de EE.UU.).

- Equidad algorítmica: ¿Se puede corregir el sesgo racial del sistema? Probamos 4 estrategias de mitigación para reducir la discriminación.
- Robustez adversaria: ¿Se puede hackear el sistema? Evaluamos vulnerabilidades y cumplimiento del Reglamento Europeo de IA.





COMPAS

El Truco Sucio: Proxy Discrimination

El modelo NO usa la variable "raza" directamente. Pero SÍ usa "condenas previas" y "edad" — variables correlacionadas con la raza por desigualdades estructurales históricas.



Quitar la etiqueta "raza" no elimina el racismo del algoritmo. Solo lo disfraza bajo otras variables. El sesgo se esconde, pero sigue decidiendo.





Las 4 Estrategias en el Ring

BASE

P.DEM

P.FPR

Cada estrategia tiene su filosofía y su precio. No hay solución perfecta, solo decisiones éticas sobre qué tipo de justicia priorizar.



Paridad de Falsos Positivos: mismo error para inocentes de cada grupo racial.



Equalized Odds: paridad en falsos positivos Y falsos negativos simultáneamente.

El Dilema Imposible

COMPAS 



El Teorema de Chouldechova-Kleinberg demuestra matemáticamente que es imposible satisfacer todos los criterios de equidad simultáneamente. Si las tasas base de reincidencia difieren entre grupos, algo hay que sacrificar.

No existe una solución mágica. Cada elección técnica es, en realidad, una decisión ética disfrazada.

¿Precisión o equidad? ¿Proteger inocentes o prevenir delitos? Solo hay dilemas difíciles.

El Trade-Off: Precisión vs. Equidad

Reducir el sesgo racial tiene un coste en precisión. La Paridad de Tasa de Falsos Positivos (FPR) reduce significativamente la disparidad racial, pero a cambio de una pérdida moderada de accuracy. No hay solución gratuita.

-12%

Pérdida accuracy:

La pregunta:

¿Cuánta justicia estás dispuesto a pagar? ¿Prefieres un algoritmo preciso o uno justo?



A hand in a dark suit is tipping a golden scale of justice. The scale is positioned on the right side of the frame, with its pans hanging from a central point. The background is dark, and the lighting highlights the metallic texture of the scale and the hand. The overall mood is serious and contemplative, symbolizing the balance between justice and bias.

El Elefante en la Sala

Elegir qué error minimizar NO es decisión técnica. Es una decisión ética. Nuestra prioridad: no encarcelar inocentes.

- Falso positivo = encerrar a un inocente. Una persona que nunca habría reincidido pierde su libertad por un algoritmo sesgado.
- Falso negativo = soltar a alguien que reincide. El sistema falla en predecir el riesgo real, pero al menos no destruye vidas inocentes.

Y además de satisfacer, se puede hackear

FGM Atacamos el modelo con FGM (perturbaciones mínimas en datos). La precisión cae significativamente.



Un acusado podría manipular sus datos para parecer "bajo riesgo". Un sistema judicial engañado así no debería estar en un juzgado.



AI

La ley europea ya lo dice

Reglamento (UE) 2024/1689 clasifica esta IA como ALTO RIESGO. Europa no permitiría COMPAS tal como está.





VEREDICTO

"El algoritmo solo es el espejo.
El problema es lo que refleja."

